

Astra — отчёт SOTA нейросетей

Фокус: бесплатные API (не UI) · качество генерации · лимиты

Дата: 13.06.2026 · Для обсуждения с коллегой · Автор: Аид

Документ собирает исследование топ-40 SOTA моделей (июнь 2026) с акцентом на бесплатное API-использование для MVP Telegram-бота Astra. UI-only сервисы (ChatGPT Free, DeepSeek Chat, Qwen Chat) исключены из основного рейтинга — они не интегрируются в бэкэнд.

Контекст проекта

Параметр	Значение
Продукт	Astra — персональные астрологические предсказания в Telegram
Аудитория	RU, женщины, «магическое мышление»
Текущий LLM	gemma4:e2b через Ollama на deadtiger (CPU, 8 GB RAM)
Формат ответа	4 предложения + совет / число / цвет дня (Astrid v2)
Цель отчёта	Выбрать бесплатные API-fallback и понять trade-offs качества/лимитов

Методология оценок (%)

Критерий	100%	0%
Текст	Claude Fable 5 / бенчмарки	Модель без текстовой генерации
Картинки	GPT Image 2 / FLUX Max	Нет image gen
Видео	Veo 3.1 / Sora 2	Нет video gen
Аудио	Eleven v3 TTS	Нет audio gen
Предсказания	Качество Astrid-прогноза (4 предл., RU)	Неприменимо
Free Score	Бессрочный щедрый API без карты	Нет API / только paid

Источники: BenchLM.ai, Artificial Analysis, Google AI docs, DeepSeek API docs, Groq docs, OpenRouter docs, Alibaba DashScope (июнь 2026). Бенчмарки — ориентир, не истина.

Рейтинг по бесплатному API (сортировка)

#	Модель	Free%	API	Free лимит	Paid от	Предск.%	Роль
1	gemma4:e2b local	100	ДА	∞	0 руб.	78	Основной MVP
2	Groq API	92	ДА	14 400 RPD	pay-go	58	Скорость
3	Gemini Flash API	90	ДА	1500 RPD	\$0.10/M+	75	Fallback #1
4	OpenRouter :free	85	ДА	50–1000 RPD	per model	68	A/B роутер
5	DeepSeek API	82	ДА*	5M tok/30д	\$0.14/M+	72	Fallback #2
6	DashScope Qwen	68	ДА*	70M/90д	\$0.40/M+	70	Trial
7	Cohere Trial	70	ДА*	1000/мес	paid	55	RAG only

8	FLUX API	65	ДА	1 req/s	\$0.03/MP	0	Картинки
9	ElevenLabs	62	ДА	10K cr/мес	\$5/мес+	0	TTS
10	HuggingFace	55	ДА	\$0.10/мес	pay-go	40	Эксперименты
11	Mistral Experiment	50	ДА	~1 RPS	paid	60	EU
—	OpenAI API	15	НЕТ	~\$5 trial	\$5–30/M	82	Только paid
—	Anthropic API	5	НЕТ	—	\$3–75/M	88	Только paid

* Trial = не постоянный free tier (DeepSeek 30 дней, DashScope 90 дней).

Матрица качества генерации (%)

Модель	Текст	Карт.	Видео	Аудио	Предск.	Free API
Claude Fable 5	98	0	0	0	95	HET
GPT-5.5	90	25	25	30	86	HET
Gemini 3.1 Pro	92	15	15	20	85	Flash free
DeepSeek V4 Flash	78	0	0	0	75	5M trial
Gemini 3.5 Flash API	80	40	30	35	82	1500 RPD
Grok 4.3	82	5	5	5	78	HET
Groq Llama 4 Scout	68	0	0	0	58	1000 RPD
gemma4:e2b LOCAL	28	0	0	0	78	∞
Qwen 3.7 Max	88	10	5	5	70	trial only
GPT Image 2	0	100	0	0	0	HET
Veo 3.1	0	10	95	60	0	HET
Eleven v3	0	0	0	98	0	10K cr

Рекомендуемый стек Astra (бесплатные API)

Приоритет 1: gemma4:e2b (Ollama) — основной, 0 руб., privacy, очередь RabbitMQ

Приоритет 2: Gemini 3/2.5 Flash API — 1500 прогнозов/день бесплатно

Приоритет 3: DeepSeek V4 Flash API — 5M токенов trial, потом \$0.14/M

Приоритет 4: Groq API — если нужна скорость (14K req/день)

Приоритет 5: OpenRouter :free — после \$10 credits → 1000 RPD для A/B

Математика MVP (100 юзеров × 1 прогноз/день): gemma4:e2b ≈ 3.3 ч CPU/день в фоне; Gemini Flash 100 < 1500 RPD ✓; DeepSeek trial 150K ток/день → 5M хватит ~33 дня.

Детальные карточки моделей (бесплатный API)

Нижe — полное описание каждой модели с free API: лимиты, условия, подключение, применимость для Astra.

#1 · gemma4:e2b (Ollama, local)

Провайдер: Google / self-hosted | Free API: ДА — REST API | Free Score: 100% | Astra-fit: 78%

Текст	Картинки	Видео	Аудио	Предсказания
28%	0%	0%	0%	78%

Тип API: Ollama REST (OpenAI-like /chat)

Endpoint: http://ollama:11434/api/chat

Бесплатные лимиты: Безлимит запросов; ~2–5 t/s на deadtiger; RAM ~1.5–2 GB Q4

Платные лимиты / цена: 0 руб. — только электричество

Условия:

- CPU-only на deadtiger (8 GB RAM, HDD)
- think=false, num_ctx=4096, num_predict=380 в Astra
- Промпт Astrid v2 откалиброван под e2b
- Генерация только в фоновой очереди (RabbitMQ)

Как подключить: OLLAMA_MODEL=gemma4:e2b в .env; docker-compose сервис ollama + ollama-init pull

Для Astra: Основной LLM для MVP: 0 руб., privacy, уже в проде. Минус: медленно (~75–190 с/прогноз).

#2 · Groq API

Провайдер: Groq (США) | Free API: ДА — постоянный free tier | Free Score: 92% | Astra-fit: 58%

Текст	Картинки	Видео	Аудио	Предсказания
68%	0%	0%	45%	58%

Тип API: OpenAI-compatible REST

Endpoint: https://api.groq.com/openai/v1

Бесплатные лимиты: Llama 3.3 70B: 30 RPM, 14 400 RPD, 6K TPM. Llama 4 Scout: 30 RPM, 1000 RPD. Whisper STT: 20 RPM, 2000 RPD

Платные лимиты / цена: Developer plan — выше лимиты; pay-as-you-go

Условия:

- Карта не нужна для free tier
- Лимиты per organization, не per key
- 429 при превышении — без очереди

- Самый быстрый free API (~300+ t/s)

Как подключить: console.groq.com → API key → base_url в OpenAI SDK

Для Astra: Fallback при пиках: быстрый, но качество прогноза ниже e2b. Whisper — STT если понадобится.

#3 · Google Gemini API (Flash)

Провайдер: Google | Free API: ДА — постоянный free tier | Free Score: 90% | Astra-fit: 75%

Текст	Картинки	Видео	Аудио	Предсказания
80%	15%	0%	0%	75%

Тип API: Gemini REST / google-genai SDK

Endpoint: generativelanguage.googleapis.com

Бесплатные лимиты: Flash: 10–15 RPM, 1000–1500 RPD, 250K–1M TPM. Imagen: 500 img/день. Pro: 50 RPD (trial)

Платные лимиты / цена: Flash ~\$0.10–1.25 in / \$0.40–5 out per M; Pro ~\$2/\$12 per M

Условия:

- Нужен billing account в GCP (иначе квота может быть 0)
- Free tier: Google может использовать промпты для обучения
- Лимиты per project — второй ключ не помогает
- Сброс RPD: полночь Pacific (11:00 MSK)
- Включение paid billing убивает free tier на проекте

Как подключить: aistudio.google.com → API key → Gemini 2.5/3 Flash model id

Для Astra: Лучший бесплатный API-fallback: 1500 прогнозов/день хватит на 100+ юзеров.

#4 · DeepSeek API

Провайдер: DeepSeek (Китай) | Free API: ДА — trial 5M токенов | Free Score: 82% | Astra-fit: 72%

Текст	Картинки	Видео	Аудио	Предсказания
78%	0%	0%	0%	72%

Тип API: OpenAI + Anthropic compatible REST

Endpoint: https://api.deepseek.com

Бесплатные лимиты: 5 000 000 токенов на старте; срок ~30 дней; карта не нужна

Платные лимиты / цена: V4 Flash: \$0.14/\$0.28 per M; V4 Pro: \$0.435/\$0.87 per M; concurrency 2500/500

Условия:

- Trial не постоянный — планируй бюджет после 30 дней

- Данные на китайской инфраструктуре — privacy риск
- Rate limits на trial = как у paid
- ~3500–6000 вызовов Astrid на trial

Как подключить: platform.deepseek.com → API key → model deepseek-v4-flash

Для Astra: Отличный стартовый API: почти фронтир за копейки. После trial — самый дешёвый paid.

#5 · OpenRouter (:free models)

Провайдер: OpenRouter | Free API: ДА — :free variants | Free Score: 85% | Astra-fit: 68%

Текст	Картинки	Видео	Аудио	Предсказания
75%	0%	0%	0%	68%

Тип API: OpenAI-compatible proxy

Endpoint: https://openrouter.ai/api/v1

Бесплатные лимиты: 20 RPM; 50 RPD (<\$10 credits) или 1000 RPD (≥\$10 credits); 28+ free моделей

Платные лимиты / цена: Per-model pricing; BYOK: 1M free routing req/мес

Условия:

- Карта не нужна для 50 RPD
- \$10 credits разово → 1000 RPD навсегда
- Модели: DeepSeek R1, Llama 3.3 70B, Qwen3, Gemma 3 :free
- Несколько аккаунтов не увеличивают лимит

Как подключить: openrouter.ai → key → model id с суффиксом :free

Для Astra: Универсальный роутер для A/B тестов. 50 RPD — только dev; 1000 — рабочий fallback.

#6 · Alibaba DashScope (Qwen API)

Провайдер: Alibaba Cloud | Free API: ДА — trial 90 дней | Free Score: 68% | Astra-fit: 70%

Текст	Картинки	Видео	Аудио	Предсказания
84%	10%	10%	5%	70%

Тип API: OpenAI-compatible REST

Endpoint: dashscope-intl.aliyuncs.com/compatible-mode/v1 (Singapore)

Бесплатные лимиты: ~70M токенов trial (1M per model); 90 дней; только Singapore endpoint

Платные лимиты / цена: Qwen-Plus \$0.40/\$1.20 per M; 600 RPM / 1M TPM

Условия:

- Постоянный free tier отменён 15.04.2026
- US Virginia endpoint — без free quota
- Включить «Free quota only» в консоли — стоп при исчерпании
- Qwen Chat (UI) бесплатен, но это не API

Как подключить: modelstudio.console.alibabacloud.com → DASHSCOPE_API_KEY

Для Astra: Щедрый trial для прототипа; после 90 дней — платный. Хорош для RU/мультиязычности.

#7 · Cohere Trial API

Провайдер: Cohere (Канада) | Free API: ДА — trial | Free Score: 70% | Astra-fit: 55%

Текст	Картинки	Видео	Аудио	Предсказания
65%	0%	0%	0%	55%

Тип API: Cohere REST (chat, embed, rerank)

Endpoint: <https://api.cohere.com>

Бесплатные лимиты: 1000 API calls/месяц (~33/день); 20 RPM chat; non-commercial only

Платные лимиты / цена: Production: Command A+ 500 RPM; Embed 2000 inputs/min

Условия:

- Trial key — только evaluation, не production
- Non-commercial license на trial
- Сильный Rerank для RAG, слабее для креатива

Как подключить: dashboard.cohere.com → Trial API key

Для Astra: Мало для MVP (33 прогноза/день). Полезен для RAG/embeddings, не для Astrid-текста.

#8 · Mistral La Plateforme

Провайдер: Mistral (EU) | Free API: ДА — Experiment tier | Free Score: 50% | Astra-fit: 60%

Текст	Картинки	Видео	Аудио	Предсказания
72%	15%	0%	0%	60%

Тип API: Mistral REST

Endpoint: <https://api.mistral.ai>

Бесплатные лимиты: Experiment: ~1 RPS, 500K TPM; точные цифры в admin.mistral.ai

Платные лимиты / цена: Tier 1–4 от pay-as-you-go; Large 3 Apache 2.0 weights

Условия:

- Лимиты только после логина в консоль
- EU data residency — плюс для GDPR
- Карта может потребоваться для регистрации

Как подключить: console.mistral.ai → API key → mistral-large-latest

Для Astra: Запасной EU-friendly API. Качество ок, лимиты скромные.

#9 · HuggingFace Inference Providers

Провайдер: Hugging Face | Free API: ДА — микро-кредиты | Free Score: 55% | Astra-fit: 40%

Текст	Картинки	Видео	Аудио	Предсказания
50%	20%	0%	0%	40%

Тип API: HF Inference / OpenAI-compatible routing

Endpoint: api-inference.huggingface.co

Бесплатные лимиты: \$0.10 credits/месяц (free account); PRO \$9 → \$2/мес credits

Платные лимиты / цена: Pay-as-you-go после исчерпания credits

Условия:

- Практически только для экспериментов
- Cold start 10–30 с на редких моделях
- Serverless: сотни req/час, <10B params

Как подключить: huggingface.co/settings/tokens → Inference Providers

Для Astra: Не для продакшена Astra. Только тест open-моделей.

#10 · FLUX API (Black Forest Labs)

Провайдер: BFL | Free API: ДА — ограниченный | Free Score: 65% | Astra-fit: 0%

Текст	Картинки	Видео	Аудио	Предсказания
0%	70%	0%	0%	0%

Тип API: REST image generation

Endpoint: https://api.bfl.ai

Бесплатные лимиты: 1 request/second; Schnell + Dev models; 1024×1024

Платные лимиты / цена: Pro/Max: \$0.03/MP; self-host Klein 4B Apache 2.0

Условия:

- Только генерация картинок

- Free tier для прототипов, не high-volume

Как подключить: [api.bfl.ai](#) → API key

Для Astra: Не v1. Для будущих визуальных фич (карта дня, share-картинки).

#11 · ElevenLabs API

Провайдер: ElevenLabs | Free API: ДА — ограниченный | Free Score: 62% | Astra-fit: 0%

Текст	Картинки	Видео	Аудио	Предсказания
0%	25%	0%	75%	0%

Тип API: REST TTS / STT

Endpoint: <https://api.elevenlabs.io>

Бесплатные лимиты: 10 000 credits/мес (~10–20 мин TTS); 3 image req/день; видео — нет

Платные лимиты / цена: Starter \$5/мес: 30K credits; commercial license с paid

Условия:

- Free: non-commercial + обязательная attribution
- Credits не rollover на free
- Max 2500 символов за запрос на free

Как подключить: [elevenlabs.io](#) → Profile → API key

Для Astra: Гипотеза #37 (аудио Astrid). Не v1. Нужен paid для коммерции.

Справочник: фронтир без бесплатного API

Модели ниже — лидеры по качеству, но для интеграции в Astra требуют платный API. Включены для сравнения качества.

Модель	Провайдер	Качество	API
Claude Fable 5 / Mythos 5	Anthropic	Текст 98%, Предск. 95%	API \$10–50/M, нет free
GPT-5.5 / GPT-5.5 Pro	OpenAI	Текст 90%, Предск. 86%	~\$5 trial ненадёжно; API \$5–30/M
Claude Opus 4.8	Anthropic	Текст 94%, Предск. 92%	API от \$5/\$25 per M
Gemini 3.1 Pro	Google	Текст 92%, Предск. 85%	API \$2/\$12, free tier только Flash
Grok 4.3	xAI	Текст 82%, Предск. 78%	API \$1.25/\$2.50, нет free tier
DeepSeek V4 Pro Max	DeepSeek	Текст 86%, Предск. 80%	Trial 5M токенов, потом paid
Kimi K2.6	Moonshot	Текст 84%, Предск. 70%	Open weights; API paid / Groq free

Сравнение: UI-only vs API (исключены из рейтинга)

Сервис	Free UI	Free API	Почему не в рейтинге
--------	---------	----------	----------------------

DeepSeek Chat	∞ fair-use	НЕТ	Только браузер, не для бота
Qwen Chat	∞	НЕТ (trial API отдельно)	UI $\neq$ API
ChatGPT Free	Лимиты + реклама	НЕТ	GPT-5.x не в free API
Claude.ai Free	~десятки msg/день	НЕТ	API только paid
Gemini App	Щедрый UI	Отдельно Gemini API	Разные продукты

Вопросы для обсуждения с коллегой

- 1. Оставляем gemma4:e2b единственным LLM или добавляем Gemini Flash API как fallback при сбое Ollama?
- 2. Стоит ли тратить DeepSeek trial (5M токенов) на A/B против e2b или беречь для других фич?
- 3. Privacy: DeepSeek/Gemini API — ок для астрологических данных (дата рождения, имя)?
- 4. При 1000+ юзеров: когда переходить на paid API и какой бюджет (\$/мес)?
- 5. Нужен ли OpenRouter (\$10 → 1000 RPD) как универсальный роутер или достаточно 2 провайдеров?
- 6. Аудио (ElevenLabs) и картинки (FLUX) — в каком релизе после MVP?

Ссылки

- Gemini API limits: ai.google.dev/gemini-api/docs/rate-limits
- DeepSeek pricing: api-docs.deepseek.com/quick_start/pricing
- Groq limits: console.groq.com/docs/rate-limits
- OpenRouter limits: openrouter.ai/docs/api-reference/limits
- DashScope: alibabacloud.com/help/en/model-studio
- BenchLM overall: benchlm.ai/best/overall